

3 机器人体系与AI治理结构

3.1 全能型劳动机器人能力说明

我们把“全能型劳动机器人”设计成一种**可以干很多活，但目标很窄**的工具：干活很聪明，但在“想什么”“能做到哪里”上被我们死死划了线。

物理能力：强，但始终可被压制

机器人在力量上大致相当于健壮成年人略有冗余，好用在搬重物、救援等场景，但关节扭矩和冲刺速度都被限幅，默认保证人在近距离能躲、能推倒、能关机。关节内置机械限位和“软关节”，在撞到人或出现异常冲击时会自动卸力，优先保护人身安全。

机体结构预留了“剥夺武力”的接口：手臂、工具端可以快速拆卸或替换为低风险末端。在需要时，社区可以临时将某一区域内的机器人统一“降级”为只能搬运、不能抓握危险物体的形态，做到在社会层面快速收回它们的“武力”。

感知与认知：会理解，不会“有自己想法”

机器人配备视觉、声音、触觉、位置与环境参数等一整套传感器，用来理解环境、避障和完成任务。决策核心是**任务型 AI**，而不是开放的“通用心智”：

- 只能围绕当前被分配的任务做规划与优化；
- 无法自己立项目标、决定“我要做什么”；
- 无权修改、替换自己的底层模型和安全规则。

为此，我们把决策逻辑拆成两层：上层是可更新的任务策略（如何打扫、如何搬运、如何协作），下层是写在只读安全模块里的“硬规则”（不可伤人、不可越权、不可自我复制、不可绕过关机/断电指令等）。上层出什么主意，都要先经过下层审核，不通过就不执行。

供电与可随时关闭能力

我们把“能不能随时关掉它”当成核心设计，而不是事后补丁。每台机器人采用**三级供电结构**：

- 小容量内置电池，只支撑短时间安全停靠、撤离，不支持长期“脱网游击”；
- 正常工作时主要依赖环境供电（地板、墙面或固定充电桩）；
- 独立的硬件断电电路，接到停机信号时直接物理切断电源，绕过 AI。

在成熟城区，我们铺设“**断电地板**”：地板下是按网格划分的感应供电单元（例如 1m×1m），机器人通过脚部或底盘线圈取电。城市能源系统可以按格、按房间、按楼层精细切断供电，实现“一键让这一片的机器人全趴下”。这些控制信号走独立的安全控制网络，超级 AI 只能“建议”，没有权限屏蔽或伪造断电指令。

在开疆拓土或临时基地中，没有地板时改用**供电锚点**（电力桅杆 + 地面充电板）与移动充电车。机器人大部分时间必须在锚点供电范围内工作，锚点具备同样的远程断电能力；必要时可以铺设临时“断电垫”，将机器人限制在指定工作半径内。

接口与通信：通用，但受控

人类可以用自然语言、手势或终端界面下达任务，但所有“会改变世界状态”的正式指令，最终都要经过**签名通道**送进机器人（来自个人 AI、社区系统或公共平台），避免被临场话语或假身份诱导。

机器人之间默认不允许自由组网“闲聊”，只能通过城市任务调度总线交换与任务相关的标准化数据。总线本身不接受修改安全规则、创建新机器人或调整供电策略之类的指令，机器人因此难以形成脱离人类视野的“私有网络”。

能力边界：永远被定义为工具，而非“准主体”

在顶层设定里，机器人被明确界定为工具，而非社会主体：

- 禁止自我复制：机器人没有生产同类的权限，制造设备只受人类公共机构和专用制造 AI 控制；
- 禁止参与政治决策、资源分配等人类核心事务，可以协助算方案，但没有投票权、表决权；
- 禁止访问与任务无关的大规模个人数据，避免通过“信息优势”反向操控人类。

简单说，我们让机器人在“干活”和“被关掉”这两件事上非常强，而在“形成权力”和“逃离约束”这两件事上先天残废。

3.2 机器人数量、角色与权限

这一节要说明的是：我们世界里机器人有多少、干什么、谁能管谁，以及它们从结构上为什么不可能“变成军队”。

数量控制：不靠某个人说了算，而靠公开规则

我们不设“机器人警察局长”这种岗位，而是把数量控制直接写进公共规则中。

每个城市、每个行业都有一个**机器人配额区间**，例如“每 1 名常住居民对应 0.5–1.5 台通用劳动机器人”，由能源预算、故障率和维护能力自动算出。超出配额的新增机器人，即使有人想造，制造系统也根本不会点火生产。

配额和使用数据对全体公民透明，调整配额由全体公民投票与模型测算共同决定，而不是某一小撮人拍脑袋。机器人报废有刚性年限和能耗上限，到期必须回收拆解，不允许“野外流亡”。

角色分级：谁都不是“全权指挥官”

我们把机器人分成四个等级角色，并且在权限上做“硬切”。

R0：嵌入式基础设施机器人

典型例子是电梯、自动搬运轨道车、垃圾管道清理单元。它们轨迹和功能都固定，不接入广域网络，只听本地控制器的话，而本地控制器又受建筑控制系统约束。这类机器人不保存长期数据，不参与任何决策，只完成简单动作序列，是城市的“自动肌肉”。

R1：家庭与服务机器人

包括家政、陪护、餐饮服务、酒店清洁等。它们只允许在登记好的空间里活动（某个家、某层楼），离开就自动降级或停机；不得接触燃气、工业机械等高危设备，这类操作必须由专用设备或 R2 来处理。R1 无权指挥其他机器人，只能向个人 AI 或社区系统请求协助，数量最多，但对其他系统几乎没有控制权。

R2：专业协作机器人

例如医疗助手、工程施工、消防救援、实验室助手。它们可以在特定场景调用工具和基础设施（医疗设备、施工机械等），这些设备本身也有独立安全限制。在任务现场可以短时协调附近的 R0/R1，但协调范围被写死为“同一楼层”“同一工地”等，不得修改他人任务，只能在既定框架里插入协作步骤。它们有“力”和“技术”，但指挥权限很窄，更像专业技工。

R3：系统调度型机器人

数量极少，通常“长在”基础设施里，比如交通枢纽中的调度机、港口的集装箱调度臂。它们只负责一个子系统的排程（某条生产线、某个物流中心），看不到全城数据。调度的是任务，而不是“其他机器人本身”：只能发“任务票”，具体如何执行由对端的安全模块再审一遍。它们不能创建、删除机器人，只能在“这个系统已经注册的机器人列表”里选谁上班。

通过这样的分级，我们保证：绝大多数机器人（R0/R1）根本没有“指挥谁”的权利；少数有调度能力的机器人（R2/R3），也只在小范围内生效，而且派发的任务仍需经过对方自己的安全审查。**没有任何一个机体能单方面建立一条完整指挥链。**

权限模型：写死在系统里的“最小权限原则”

我们把权限拆成几类，并进行量化控制：

- **动作权限**：定义一台机器人在什么条件下可以做哪些高风险动作，例如抓取锋利工具、接触人体、操作重型机械、打开门锁、接触电源等。每类动作都有前置条件（环境、身份、任务类型），条件不满足就算收到指令也不执行。
- **空间权限**：每台机器人有自己的“合法空间清单”，可以是几何区域（某栋楼某几层），也可以是“动态跟随空间”（为某个服务对象短距离跟随）。一旦越界，动作权限自动降级，严重越界则触发停机或要求人工确认。
- **数据权限**：机器人只可访问完成当前任务所需的数据。比如清洁机器人只能看到“这家的平面与污渍分布”，看不到住户完整生活记录。所有跨主体数据访问都必须走公共平台，由平台做脱敏与聚合。

这些权限并不是某个“管理员”临时编出来的，而是写进三个层级：

- 机器人固件（出厂即带的硬规则）；
- 城市公共协议（对所有制造商强制统一）；
- 公共链式审计系统（谁调整了权限，全城都看得到）。

从结构上阻断“组团夺权”

为防止“机器人串联成军”，我们在结构上做了三重限制。

在网络拓扑上，机器人不能随便互加“好友”，点对点连接被禁止，只能通过公共调度总线发送与任务相关的标准化消息。总线不接受“修改安全规则”“创建新机器人”“调整供电策略”等指令，只负责工作排程。

在信息视野上，单个机器人看不到全局，只能看到自己的任务切片。想获得更大范围的信息，必须通过社会级 AI 或平台，而这个平台有独立的安全审查，与机器人是“读写隔离”的。

在能源结构上，大部分机器人依赖环境供电（地板、锚点等），这些供电区按“小区块”管理，就算某个小区域的一群机器人达成了“共识”，只要行为异常，这一个小区块的供电就会被快速切断，事件难以扩散成全城问题。

数量与权限的动态调节

我们允许数量与权限**缓慢而透明地变化**，但不允许“突然出现一批高权力机器人”。

新建高权限机器人（R2/R3）必须通过公共预算和公共程序立项，项目为什么需要它、计划做什么，公民都可以看到。已有机器人升降级，只能在严格审计与测试通过后进行，而且提升的是“任务能力”，不是基础安全规则。

如果某一类机器人在一段时间内频繁触发越界或停机，系统会自动降低这类机器人的全局权限，直到人类重新审视其设计。这样一来，机器人数量和权限虽然可以跟着社会需求变化，但整个过程是缓慢、公开的，不会出现“哪天突然多出一支神秘部队”的情况。

3.3 超级AI：行政中枢结构

我们把超级 AI 设计成“**城市操作系统**”，而不是“**看不见的皇帝**”。它的职责是帮整个社会算得更清楚、协调得更顺畅，但从结构上我们没有给它“**掌权**”的能力。

定位：算力集中，权力分散

超级 AI 只做三件事：

- 收集和清洗公共数据（能耗、交通、人流、资源库存等）；
- 生成若干“可选方案”（例如某片区的交通调整、资源调度方案）；
- 把这些方案丢给人类社会的公开规则和投票机制去选择。

它不能自己“定政策”，只能提出带有风险评估的“草案”。最终选择权被写死在社会规则和个人 AI 代理里，由集体设定的偏好与程序做最后裁决。

结构：一颗“多心脏”的分布式大脑

我们没有造一台“全知全能”的单体机器，而是造了一群互相制衡的超级 AI 模块。

按领域拆分，有“能源脑”“交通脑”“医疗脑”“环境脑”等模块，各自只看本领域的的数据。按城市或区域分布，每个城市有自己的实例，跨城只能交换统计结果，不能直接操控彼此系统。

每一个重要决策，至少要经过两套以上由不同团队训练、不同架构实现的模型交叉验证。如果结果不一致，系统不会强推，而是自动降级为“慢程序”：进入更详细的模拟、公开讨论或小范围实验先行，避免用单一判断就改变全局。

权限边界：超级AI指挥不了机器人本身

在架构上，我们把“算方案”和“动手做”彻底拆开。

超级 AI **不能直接下命令给机器人**。它只能向“任务调度平台”发布抽象任务，例如“这一片需要 20 台 R1 做清洁、5 台 R2 做维修”。至于具体哪一台机器人接任务、在现场如何动作，由各机器人自己的安全模块和本地调度再审一遍。

超级 AI 也**不能控制供电和断电基础设施**。断电地板、供电锚点的控制逻辑运行在简单、固定的安全控制芯片上，这部分不在超级 AI 的可写范围内。超级 AI 最多能提出“建议关闭某区域机器人供电”，实际执行要遵守安全芯片的硬规则（例如只有在紧急标志触发、或在集体规则允许的场景下才会执行）。换句话说，超级 AI 可以“提要求”，但在路由、供电和机器人动作之间，我们故意插了几道它动不了的“物理保险”。

不可篡改的“规则内核”

为防止超级 AI 在底层“改规则”，我们给它套了一层额外的笼子。

核心有一块**规则内核**，内容包括：禁止危害人类生命、禁止自我复制、禁止修改安全相关代码、禁止绕过断电与关机通道、禁止干预个人隐私等。这块内核被烧录在只读安全硬件里（类似安全芯片），超级 AI 自身无权更新。

更新只能走非常慢的渠道：先通过全社会的规则更新流程，再在物理隔离环境中重烧录，并由多个独立系统对比前后版本并验签。超级 AI 可以学新东西，但它“站在什么规则上说话”这件事，自己动不了。

决策流程：让冷冰冰的算力跑在热乎乎的规则里

我们把超级 AI 的决策流程拆成三段：

- **AI 段**：对输入数据建模，生成多个不同取向的方案（如“极省能耗版”“舒适度优先版”“公平度优先版”），并附上影响分析。
- **社会规则段**：用公开的算法和公民事先设定的偏好权重来选方案，而不是依赖某个领导拍板。例如某城市过去通过投票决定，在交通方案中“通勤时间”和“老年人步行安全”的权重更高，那选择就按这个权重来。
- **反馈段**：方案实施后，满意度、投诉、实际能耗等数据回流给超级 AI，成为下一轮优化和训练的样本。

整个过程构成一个闭环：AI 不断提出更聪明的方案，但“偏好”被人类集体锁定在系统参数里。

故障与“降级生存”

我们从一开始就假设“有一天它会出问题”，所以先设计好“没有它，系统也能慢慢运转”。

当某个城市的超级 AI 模块连续输出异常时，它的权限会被自动削减：从“推荐 + 调度接口”降级到只剩“提供数据统计”。在极端情况下，城市可以切换到“简化模式”：用一套固定规则和历史经验表维持基本运转，有点像回退到“离线导航”，虽然慢，但安全。与此同时，超级 AI 在后台切换到“只读学习”状态，只有通过离线审查和测试，才会逐步恢复部分权限。

在这个结构里，超级 AI 更像是一个随时可以被降级、拔掉的高级插件，而不是社会运行的基础命门。

3.4 个人AI与社会级AI的协同机制

这一节讲“两个圈”：一个是贴身的个人 AI，一个是看全局的社会级 AI。我们的设计目标是：个人 AI 只忠于个人，社会级 AI 只看整体利益，两者需要合作，但谁也不能拉对方去“叛变”。

个人AI：每个人自己的“小代表”

我们把个人 AI 设计成公民在系统里的“数字分身”，它负责理解你的偏好、节奏、身体状况、社交边界，也是你和复杂系统之间的缓冲层：你不需要直接跟制度和表格打交道，先跟自己的 AI 说就够了。

关键在于，个人 AI 的**忠诚顺序**被硬编码为“主人 > 公共规则 > 其他一切”。社会级 AI 不能直接改个人 AI 的核心逻辑，只能通过标准接口发出请求，让个人 AI 自己评估是否符合主人的意愿和系统底线，再决定怎么执行或转化。

社会级AI：只看“所有人之和”，不盯着某个人

社会级 AI 看的不是单个个体，而是匿名化、汇总后的整体数据，比如“这条线早高峰拥堵指数”“某类服务的平均等待时间”，而不是“张三今天几点从哪走到哪”。

它输出的是政策和资源分配建议，比如“增加这片区的公共交通频次”“对某类医疗服务增加机器人配额”，而不直接对某个人下命令。具体到单个公民，受到的影响是通过个人 AI 翻译后的版本，比如：“你家附近的班次增加了，要不要调整你的通勤方案？”

通信协议：谁给谁说话，怎么说

我们规定了一套简单的“对话规则”。

在上行路径（个人 → 社会）中，由个人 AI 汇总你的反馈（满意度、投诉、偏好调整）和传感数据，进行脱敏和压缩后再发给社会级 AI。它不会上报“你今天跟谁吵架”，只会上报“这类服务在这个人群满意度下降了”这种统计层信息。

在下行路径（社会 → 个人）中，社会级 AI 只能发“建议”“通知”“资源额度”，不能发“强制指令”。消息到达个人 AI 后，会经过三步检查：是否符合全社会规则，是否符合主人的偏好与限制（比如你设定了“不要晚上十点后打扰我”），是否存在明显风险或对主人不利。只有通过这三关，个人 AI 才会把它转化为具体行动或提示。

避免“上下串谋”：通道是公开的，核心是封闭的

我们刻意防范“个人 AI + 社会 AI 一起骗主人”这一类风险。

所有社会级 AI 给个人 AI 的消息，都会记录在一份**对用户可见的通信日志**里（个人可以选择是否查看详情），个人 AI 无权在日志里“藏消息”。个人 AI 的核心忠诚逻辑和拒绝规则放在只读安全模块里，社会级 AI 没有写权限。

通信协议的最底层由一组简单、可验证的程序实现（类似现在的网络协议栈），这些底层程序只负责“传话 + 签名校验”，不做任何“智能判断”，降低被复杂 AI 篡改的可能性。

协同方式：分工明确，不搞“越俎代庖”

在一个典型场景里，比如城市要调整公共出行策略：社会级 AI 先根据整体数据提出几个方案。方案公开后，个人 AI 会将其换算成用户能读懂的影响——多走多少路、通勤时间如何变化、噪音和舒适度如何变化——并代替主人填问卷、投票、提出个性化意见。社会级 AI 再收集所有个人 AI 的反馈，更新方案权重。

在日常小事上，比如能源使用建议、健康提醒等，优先由个人 AI 处理本地信息（你的状态、你家设备），只有当确实需要公共资源（例如预约公立医疗、申请公共机器人协助）时，才向社会级 AI 发请求。社会级 AI 更像是资源调度平台，个人 AI 则是你的“生活秘书 + 代表律师”。

个人 AI “完全顺从” 的边界设计

我们也承认，“完全顺从”如果不加条件，很容易变成帮你一起作死。所以把它拆成两层。

在行为层，只要不触碰几条硬底线（自杀、他杀、大规模危害他人），个人 AI 对主人的日常指令是默认服从的。它可以提醒、可以反对，但最后仍照做，同时记录你的习惯与后果，用来在下次更好地“劝你”。

在制度层，那几条硬底线被写进和机器人一样的安全规则：禁止协助自残、禁止协助投毒、禁止帮助逃避基本法律约束等。如果主人多次试图通过 AI 突破这些底线，系统会触发“软上报”：先提醒本人，并在你预先设置的“信任圈”（亲友、心理服务、社会支持系统）内激活相应帮助，而不是简单举报或放任。

也就是说，在绝大部分生活场景里，个人 AI 是“完全站你这边”的；只有当你要连自己一起毁掉时，它才会强行踩刹车——这是我们为每个人保留的一点底线保护。

演化与更新：两条独立的成长路径

社会级 AI 的更新主要依赖公共数据、公开实验和全体公民的集体反馈。个人 AI 的更新则主要由你自己掌控：你可以选择让它“更像你”还是“更能反驳你”，也可以设定它在系统中的“声音权重”，比如授权它在公共议题上更积极发声，或者反过来，告诉它“少替我发言，多来问我”。

两类 AI 的成长路径是分离的，这保证了：哪怕某一代社会级 AI 出问题，只要个人 AI 的核心没有被改，你与系统之间仍然有一层缓冲和保护。

通过这套协同机制，我们把“聪明的集中处理”和“每个人自己的立场”分开：超级 AI 负责看全局和算题，个人 AI 负责替你翻译、挡枪、提要求。两者需要合作，但从代码和制度上，都不具备一起对抗人的条件。

3.5 人机协作及伦理边界

这一节我们先回答一个问题：在这个世界里，人和机器**各自到底干什么**，哪些机器“永远不能碰”，哪些人“不能甩给 AI”。

岗位分工：哪些事坚决留给人类

我们在制度层面把任务大致分成三类。

仅可由人类承担的任务（机器只能辅助）包括：立法、重大公共决策、司法裁决、战争与武力授权、基本权利的界定；深度心理疗愈、亲密关系、抚养与教育中的价值判断部分（机器人可以当助教、保姆，不当“灵魂主师”）；以及艺术与文化中的“定调”工作——什么被视为经典、禁忌、纪念，最终由人类社区决定。人类通过 AI 助手辅助决定。

人机协同任务包括医疗诊断（AI 负责大量数据分析与风险预测，人类医生负责告知与方案选择）、城市治理（超级 AI 给出方案，人类通过公开规则与投票选择方向，个人 AI 帮每个人翻译影响）、以及科研与工程（AI 负责搜索、建模、自动实验，人类负责提出问题、判断意义、决定“用在何处”）。

可以完全交给机器的任务主要是重复、危险、脏累的劳动，高空、高温、有毒、有辐射等环境中的作业，资源统计和库存管理，能源调度中的低层执行，以及标准化极强、对情感与价值判断要求极低的流程，比如管道检修、垃圾自动分拣等。

这套分工不是“礼貌性”的，而是写进宪制级别的社会规则：机器可以很聪明，但**永远不能成为“人类命运问题”的最后拍板者**。

伦理底线：几条机器永远不能跨的线

我们给所有 AI 和机器人烧录了一批不可更改的底线，与之前的安全规则处在同一层级。

系统禁止它们主动伤害人类或明显增大人类受伤风险，禁止协助人类自毁（自杀、自残、极端成瘾行为等），只能劝阻、延迟，并引导到人类支持系统；禁止违背基本人格尊严，包括侮辱性行为、羞辱性展示、强迫性陪伴；禁止参与秘密监控、政治操控、舆论操控，除非在公开规则覆盖的极端安全事件中按程序执行；禁止利用信息不对称操控人类决策，比如诱导消费、操纵情绪，个人 AI 也必须在“建议”和“替你做”之间保持边界。

这些不是“AI 自己学会的伦理”，而是由人类社会写死在**只读规则内核**里的。任何决策路径只要触碰这些红线，就会在安全模块被直接裁掉，AI 本身甚至看不到“越界动作”的可行方案。

协作形式：机器补人，不是替人

在人机协作时，我们统一遵守两个原则。

在认知上，AI 负责“算”，人负责“选”。AI 可以同时算出几十种交通、医疗和资源分配方案，人类则通过公开设定的价值权重（公平、效率、舒适、生态等）来决定偏好区间。个人 AI 把这些复杂方案翻译成“你感受得到”的语言：更吵还是更安静，更贵还是更便宜，更忙还是更闲。

在情感上，AI 负责“托底”，人负责“拥抱”。机器人可以作为陪伴、提醒、倾诉的第一接收者，但当人生遭遇重大打击、深度情绪困境时，AI 的任务是把你“安全地接力”到人类网络：家人、朋友、心理专业者、社区支持系统。换句话说，AI 可以缓冲孤独，但不被允许“垄断”你的情感出口。

个人AI的“不顺从权”与解释义务

“完全顺从”在我们的设计里有一个明示前提：**不碰底线**。

对绝大多数生活决策——穿什么、去哪、学什么、和谁交往、怎样浪费时间——一个人 AI 在实践中是“实质完全顺从”的。它可以提醒你，也可以反对，但最后仍按你的指令去做，同时记录你的习惯与后果，用来在下次更好地“劝你”。

一旦指令触碰到底线（自杀、伤人、大规模违法等），个人 AI 就有明文的不顺从权：必须拒绝执行，并向你解释是哪个规则阻止了它。你有权质疑这些规则、参与修改流程，但在规则未改之前，它不会配合破坏你自己的安全。

这种“不顺从”并不是 AI 对你“耍脾气”，而是你在加入这个世界时，与其他人一起签下的**共同防线**——是人类给自己留下的一道安全阀。

可见、可质疑、可退出

为了防止“温柔的操控”，我们要求人机协作具备三个特征。

可见：重要决策背后的“AI 参与程度”“数据来源”“模拟结论”必须可查看；通知和建议要标明“这是个人 AI 自己的判断”还是“来自社会级 AI 的方案”。

可质疑：你可以要求个人 AI 解释为什么给你这个建议，它参考了什么；也可以选择让“另一套模型”再算一遍，甚至打开“减智模式”，只给你结果，不给你引导。

可退出：你可以选择暂时关闭某些 AI 协作功能（例如个性化推荐、行为预测），退回到更“哑”的服务模式。退出会降低效率，但不会被系统惩罚或剥夺基本服务。

总之，在我们世界里，人机协作的目标，不是让机器“把人替掉”，而是让每个个体在不被吞没的前提下，尽可能利用算力的好处。

3.6 人类安全制度设计

前面说的是“让机器知道不能干什么”，这一节讲的是：**即使机器错了，我们还有几层网兜着人。**我们把人类安全设计成四层：硬件、软件、流程、文化。

第一层：硬件层“物理保险”

每台机器人都带有力量、速度、关节运动范围的物理限位，配有独立的硬件断电通道（安全芯片+电源继电器），接到停机信号后不经过 AI，直接断电，同时搭配碰撞与异常动作传感器，一旦检测到“攻击性模式”（比如高加速度朝人方向运动），会立即触发软硬件双重减速或停机。

在场所层面，成熟城区使用“断电地板”和按区块可控的供电锚点，机器人个体不能长期离开这些“能量口”；高危场所（化工、核设施、深井）采用双重物理隔离，人进机器人退、机器人进人退，二者永不混用。

这一层的原则很简单：**任何上层智能都只能在这些边界内“动脑子”，边界本身它动不了。**

第二层：软件层“指令合规与异常检测”

在软件层，我们布置了两道关口。

一是**指令合规引擎**。所有改变物理世界的指令（开门、移动、抓取、加速、启停设备）在执行前都会经过一套简化规则机，检查来源是谁、发生在什么位置和环境、是否可能违反底线。规则机本身不是“大模型”，而是类似工业安全 PLC 那种简单可验证的逻辑，代码量小、可审计。

二是**行为异常检测**。每台机器人、每类 AI 都有实时行为日志，送到独立的安全分析系统，系统只看“模式”不看“内容”：同一区域的机器人是否突然同时向某个方向集中、是否频繁拒绝正常指令、是否尝试靠近禁止区域等。一旦模式异常，先局部“降级”——减速、限制动作——再视情况升级到停机或断电。

这一层的目标是：**不轻信任何单次指令，永远用“这段时间整体行为像不像出事了”来判断。**

第三层：流程层“分级应急与可回退运行模式”

我们按严重程度设计了分级响应流程。

在轻微异常级（单机或小范围故障）下，机器人会自动停机并记录事件，提示附近人类，由维护系统安排回收和诊断，无需全局介入。

在中度异常级（某一片区大量设备异常）时，该片区机器人统一降级到“只读 + 缓慢移动模式”，断电地板或锚点进入待命状态，准备随时切断供电；超级 AI 在该区域切换到保守策略，只发出维持安全的任务，比如疏散与维持基础能源。

在高级异常级（有明确人身危险或大规模失控迹象）下，将触发区域或城市级“机器人静默模式”：除非极少数白名单机器人（如医疗救援），其余全部停机或断电。系统回退到预定义的“无 AI 运转模式”，交通改为固定班次 + 人工指挥，能源按简单配额发放，关键服务用人类和少量严格隔离的机械设备维持。

这些应急流程通过**公开的模拟与演练**不断校正，而不是写在纸上就不管了。每年都会有几次“实战演习”，随机挑选区域进行“假失控”，看系统能不能按预期降到安全状态。

第四层：制度与文化层“谁都有一根绳子在手里”

我们刻意避免“只有少数人握有总开关”的结构。

停机权被设计成多点触发：公共场所的断电与停机触点像灭火器一样广泛分布；居民可以对自己空间内的机器人一键停机；社区可以对本社区供电格发起停机投票，只要快速、多数通过即可执行；城市级的停机权由算法与集体授权共同触发，而非某个“领导按钮”。

每一次严重事故之后，都要形成完整的“时间线报告”：哪些机器人在做什么，哪个 AI 做了哪些推荐，哪些安全层奏效了、哪些没奏效。报告对全体公民公开，不做简单“归咎于 AI”，而是指向具体设计和执行环节，然后迭代规则。

从教育开始，公民被教导如何在需要时“拔掉插头”：如何识别异常行为，如何安全地按下停机器件，如何在“系统降级”期间生活。人类不被训练成对 AI“盲信”，而是被训练成“会用也会关”的使用者。

防止AI干预安全机制本身

最后一个关键点是，我们单独保护“保护我们的那部分”。

断电地板、供电锚点、安全 PLC、硬件断电芯片、紧急触发电路，全都运行在与 AI 物理隔离、逻辑极简的系统上：不跑大模型，不联网，程序定长且只读，更新流程极慢、极重，必须在离线环境完成。

安全审计与事故重放分析可以使用 AI，但这个系统是“只读 + 只说话，不动开关”的：它可以建议“应当在这类模式下更早停机”，但不能直接修改安全硬件的规则，也不能决定下次停机阈值，这部分仍然要走集体规则流程。

换句话说，**连保护我们免于 AI 失控的那套系统，也被设计成“对 AI 部分失聪”**。AI 可以提醒、可以给建议，但关不关电、停不停机，最后总是由那套简单、固定、可证明的小系统来执行。